

Detecção e Contagem de Células Cervicais a partir de Anotações Pontuais

Jean Carlos Rodrigues Sousa¹, João Antônio Leal de Miranda¹,
Romuere Rodrigues Veloso e Silva¹

¹Campus Senador Helvídio Nunes de Barros (CSHNB)
Universidade Federal do Piauí (UFPI) – Picos, PI – Brasil

{jean.rodrigues, joaoantonio, romuere}@ufpi.edu.br

Resumo. *Anotações pontuais identificam centros celulares, mas não definem a extensão do objeto. Este trabalho avalia um fluxo de detecção e contagem de células cervicais na CRIC Cervix a partir desses pontos, investigando dez tamanhos de pseudo-caixa (48–192 pixels) e três escalas YOLO11, com partições separadas por imagem. O F1 de validação forma um platô entre 96 e 192 pixels, com compromissos distintos de precisão, revocação e contagem; o alvo de 144 pixels foi mantido como ponto operacional intermediário e o YOLO11s deu o melhor equilíbrio. No teste retido, alcançou AP50=0,8723, F1=0,8190 e erro absoluto médio de 4,68 células por imagem. Um critério de distância ao ponto, independente da caixa sintética, produz F1 equivalente, confirmando localização real dos núcleos. A contribuição é uma análise auditável de como a construção do alvo afeta localização, calibração e contagem, sem reivindicar caixas anatômicas ou uso diagnóstico.*

1. Introdução

O rastreamento do câncer do colo do útero depende de programas capazes de identificar alterações precursoras antes da progressão da doença. Em 2020, foram estimados aproximadamente 604 mil novos casos e 342 mil óbitos no mundo, com maior carga onde vacinação, rastreamento e tratamento são menos acessíveis [Singh et al. 2023]. Na citologia convencional, a automação tem sido estudada em classificação de recortes, segmentação, detecção de instâncias e análise de campos ou lâminas [Jiang et al. 2023].

Essas tarefas dependem do tipo de anotação disponível. Um ponto informa onde uma instância está, mas não sua extensão; uma caixa acrescenta uma região aproximada; uma máscara descreve fronteiras. Portanto, transformar pontos em caixas não é apenas uma conversão de formato: é uma decisão sobre qual região o detector deve aprender. Em campos com muitas células, essa decisão também afeta sobreposição entre alvos, localização e contagem [Chen et al. 2023, Chen et al. 2021, Xia et al. 2023].

A CRIC Cervix disponibiliza 400 imagens convencionais de Papanicolau e 11.534 células classificadas, cada uma associada a uma coordenada nuclear [Rezende et al. 2021]. A base permite estudar detecção sem recortar previamente as células, mas não fornece bounding boxes anatômicas. Trabalhos anteriores usaram a CRIC em detecção e classificação [Kalbhor et al. 2023]; ainda assim, a sensibilidade do resultado à geometria criada a partir dos pontos permanece pouco explorada.

Este artigo formula o problema como detecção e contagem supervisionadas por pontos. Não se propõe uma nova arquitetura nem se usa a categoria Bethesda como saída:

todas as coordenadas são tratadas como instâncias de uma classe única. O objetivo é determinar em que medida um detector treinado com pseudo-caixas recupera os pontos anotados, preserva a contagem por campo e quais erros aparecem quando essa saída é vista como etapa anterior a classificação ou revisão assistida.

Três perguntas orientam o experimento. **RQ1:** quanto o tamanho da pseudo-caixa modifica F1, AP50 e erro de contagem? **RQ2:** aumentar a escala de YOLO11n para YOLO11s ou YOLO11m melhora o compromisso entre localização e contagem? **RQ3:** a configuração selecionada na validação mantém desempenho no conjunto de teste retido? A principal contribuição é tornar mensurável uma decisão normalmente escondida na preparação dos dados, com partições por imagem, limiar escolhido sem acesso ao teste e intervalos de confiança por bootstrap sobre imagens completas. Essa formulação desloca o foco de uma escolha isolada de hiperparâmetro para a validade do fluxo ponto–detecção–contagem em citologia cervical.

2. Trabalhos relacionados

Máscaras de instância permitem avaliar fronteiras e separar objetos adjacentes, mas exigem um ground truth ausente na CRIC. Pontos reduzem custo de anotação e identificam instâncias sem descrever sua extensão [Chen et al. 2021, Xia et al. 2023, Chen et al. 2023]. Em imagens biomédicas, Chen et al. propuseram segmentação histopatológica fracamente supervisionada com pontos esparsos [Chen et al. 2021], enquanto Xia et al. exploraram pontos e colorização para segmentação nuclear [Xia et al. 2023]. Na detecção de objetos, o P2BNet aprende a extensão a partir de anotações pontuais [Chen et al. 2023]. Essa frente fornece a ancoragem metodológica mais próxima deste artigo: o ponto é tratado como supervisão espacial incompleta, e a região usada pelo detector passa a ser uma escolha experimental.

Em citologia cervical, revisões recentes destacam resultados elevados em classificação, mas também grande heterogeneidade de bases, classes, preparação e protocolos de avaliação [Jiang et al. 2023]. O CerviCell-detector avaliou detectores de objetos em imagens de Papanicolau, incluindo experimentos na CRIC, com formulações binária e Bethesda [Kalbhor et al. 2023]. O presente estudo se aproxima dele pelo domínio e pela base de dados, mas remove a decisão diagnóstica do alvo e pergunta se todas as instâncias pontuais podem ser localizadas e contadas. Assim, sua contribuição comparável à literatura não é superar numericamente modelos de segmentação ou classificação, mas quantificar o efeito de transformar um ponto em uma região de treinamento para detectores de caixas.

3. Metodologia

3.1. Dados e partições

Foram usadas as 400 imagens e as 11.534 coordenadas celulares da CRIC Cervix [Rezende et al. 2021]. As categorias Bethesda foram preservadas nos metadados para auditoria, mas não participaram do treinamento: a classe única *cell* agrega as seis categorias da base, de células normais (58,8%) a lesões de alto grau e carcinoma (HSIL 14,8%, LSIL 11,8%, ASC-H 8,0%, ASC-US 5,3% e SCC 1,4%). Assim, a tarefa é de localização agnóstica à classe sobre um conjunto clinicamente heterogêneo.

A imagem foi a unidade de partição, na proporção 80/10/10. Para evitar concentração de carga celular em uma partição, as imagens foram ordenadas pelo número de

células e atribuídas de forma gulosa à partição mais distante de sua meta proporcional de objetos (semente 42). O procedimento destinou 320 imagens ao treino, 40 à validação e 40 ao teste, com 9.236, 1.149 e 1.149 células, respectivamente. Nenhuma imagem foi compartilhada entre partições. Como a CRIC não disponibiliza identificador de paciente, a separação por imagem é o maior controle de independência suportado pelos metadados, não uma garantia de independência clínica.

3.2. Construção do alvo e treinamento

Para um ponto nuclear (x_i, y_i) e lado s , definiu-se a pseudo-caixa

$$B_i(s) = \left[x_i - \frac{s}{2}, y_i - \frac{s}{2}, x_i + \frac{s}{2}, y_i + \frac{s}{2} \right], \quad (1)$$

recortada aos limites da imagem e normalizada no formato YOLO. A transformação fixa o centro fornecido pelo especialista, mas introduz uma hipótese sobre extensão. Essa hipótese foi testada para $s \in \{48, 64, 72, 96, 112, 128, 144, 160, 176, 192\}$ pixels.

O experimento foi encadeado em três fases. Na RQ1, cada valor de s foi avaliado com YOLO11n por até 35 épocas, isolando a sensibilidade ao alvo. Na RQ2, fixou-se $s = 144$ e foram comparados YOLO11n, YOLO11s e YOLO11m. Na RQ3, apenas o YOLO11s selecionado e o limiar definido na validação foram avaliados no teste retido.

Os modelos YOLO11 foram inicializados com pesos pré-treinados. Usou-se AdamW, taxa inicial 0,002, agendamento cossenoidal, *mosaic* moderado, variações geométricas/cromáticas e precisão mista. YOLO11n e YOLO11s receberam entrada nominal 832; YOLO11m, 864. Os lotes foram 12, 6 e 4, respectivamente. As comparações de capacidade tiveram 80 épocas máximas e paciência 20. O treinamento foi executado em uma RTX 3060 Laptop com 6 GB de VRAM.

3.3. Avaliação

As predições foram exportadas pela rotina de validação do Ultralytics, sem aumento no teste, e todas as métricas foram recomputadas a partir delas. A associação predição–alvo priorizou maior IoU e impôs unicidade de ambos os lados. A AP em IoU 0,30, 0,50 e 0,75 foi obtida por interpolação de 101 pontos; precisão, revocação e F1 completam o conjunto.

Como a pseudo-caixa é sintética, adotou-se ainda um critério independente da sua geometria: uma detecção é correta se o centro da predição estiver a até R pixels do ponto nuclear anotado, com associação gulosa única por menor distância. O limiar de confiança foi escolhido, em cada configuração, pelo maior F1 na validação em IoU 0,50. Na fase RQ2/RQ3, os três modelos comparados atingiram pico em 0,35; o valor do YOLO11s foi usado na abertura do teste.

Para cada imagem j , com contagem anotada g_j e predita p_j , foram calculados

$$\text{MAE} = \frac{1}{N} \sum_j |p_j - g_j|, \quad \text{bias} = \frac{1}{N} \sum_j (p_j - g_j). \quad (2)$$

RMSE e correlação complementaram a análise. Intervalos de 95% foram obtidos com 1.000 réplicas de bootstrap sobre imagens completas, preservando a dependência

entre células do mesmo campo. Nenhuma métrica de teste foi usada para alterar pesos, lado da caixa ou limiar.

3.4. Rastreabilidade

Cada etapa produziu artefatos persistentes: listas de imagens por partição, metadados das pseudo-caixas, configurações de treino, históricos por época, pesos selecionados, previsões por imagem e tabelas de métricas. Figuras e valores reportados derivam desses arquivos, sem transcrição manual. As decisões foram encadeadas de modo unilateral: RQ1 definiu a região de pseudo-caixas; RQ2 comparou capacidades com o mesmo alvo; a validação selecionou confiança; e somente então o teste foi avaliado. O sweep é tratado como análise exploratória, pois uma execução por configuração não separa totalmente efeito do alvo e variação de treino.

4. Resultados

4.1. Sensibilidade ao tamanho do alvo

A Figura 1 mostra que o efeito do tamanho da pseudo-caixa foi não monotônico. F1 e AP50 aumentaram das menores caixas até uma região de estabilidade, mas o tamanho 160 apresentou queda acentuada e supercontagem. O maior F1 foi 0,8253 em 192 pixels. O menor MAE (3,65) e o maior AP50 (0,8776) ocorreram em 176 pixels. Em 144 pixels, F1 foi 0,8228, AP50 0,8748 e MAE 4,40.




Figura 1. Sensibilidade ao tamanho do alvo na validação. O marcador maior indica a configuração de 144 pixels usada na comparação de capacidade.

Os valores entre 96 e 192 pixels, exceto 160, formam um platô estreito de F1 (0,8157–0,8253); logo, os dados não sustentam um único tamanho universal. O ponto de 144 pixels foi mantido por combinar AP50 próxima do máximo (0,8748 vs. 0,8776 em 176), revocação superior a 176 e 192 (0,8285 vs. 0,7885 e 0,8059) e posição intermediária no platô. A instabilidade em 160 pixels não deve ser lida como benefício de caixas maiores: nesse ponto, o detector saturou o teto de 300 detecções por imagem na validação, com revocação 0,955 e precisão 0,496, sugerindo problema de calibração do ponto operacional em um treino isolado.

4.2. Capacidade do modelo e limiar

Com pseudo-caixas de 144 pixels, YOLO11s apresentou o maior F1 (0,8363), AP50 (0,8848) e o menor MAE (4,68) na validação. YOLO11n ficou próximo, com F1 0,8231 e

MAE 4,83. YOLO11m atingiu a maior revocação (0,8921), mas sua precisão de 0,7158 elevou o MAE para 8,13 e reduziu F1 para 0,7943. A vantagem do YOLO11s sobre YOLO11n foi pequena (0,0132 em F1 e 0,0075 em AP50), portanto suporta a escolha operacional neste experimento, não uma afirmação geral de superioridade arquitetural. O YOLO11m foi descartado porque o aumento de revocação não compensou falsos positivos e erro de contagem.

Esse comportamento ilustra por que mAP de treinamento não deve ser o único critério. Detectar mais candidatos pode ser desejável em uma etapa de busca, mas transfere custo para supressão de duplicidades ou revisão posterior, sobretudo em campos densos. Assim, a escala do modelo não foi tratada como proxy automática de qualidade.

Na seleção do ponto operacional, limiares baixos preservaram quase todas as células, mas geraram muitas detecções excedentes: em 0,10, a revocação foi 0,9661 e a precisão 0,5187, com MAE 24,78. Em 0,50, a precisão subiu para 0,8853, mas a revocação caiu para 0,6919 e o viés tornou-se negativo (−6, 28 células por imagem). O limiar 0,35 maximizou F1@0,50 (0,8363), com precisão 0,7983, revocação 0,8782, MAE 4,68 e viés 2,88. O teste recebeu 0,35 sem novo ajuste. A proximidade entre as curvas em IoU 0,30 e 0,50 indica que, nesse intervalo, a maioria das associações aceitas no critério mais flexível também satisfaz o critério de 0,50. A separação em IoU 0,75 evidencia a penalização adicional por desalinhamento fino com a pseudo-caixa; portanto, o resultado de teste mede transferência do ponto operacional, não o melhor limiar retrospectivo para aquela partição.

4.3. Teste retido

Com YOLO11s, lado 144 e confiança 0,35, o teste produziu 975 verdadeiros positivos, 257 falsos positivos e 174 falsos negativos. A Tabela 1 reúne as medidas com intervalo de 95% obtido por bootstrap de imagens.

Tabela 1. Resultado no teste retido. IC95% por bootstrap de imagens.

Métrica	Valor	IC95%	Métrica	Valor	IC95%
Precisão	0,7914	[0,746; 0,833]	AP30	0,8843	[0,858; 0,913]
Revocação	0,8486	[0,822; 0,877]	AP50	0,8723	[0,843; 0,904]
F1	0,8190	[0,796; 0,842]	AP75	0,7515	[0,695; 0,811]
MAE	4,675	[3,150; 6,425]	RMSE	7,216	[4,560; 9,850]
Viés	2,075	[0,050; 4,126]	Correlação	0,9434	[0,874; 0,979]

Em média, o teste teve 24,4 verdadeiros positivos, 6,4 falsos positivos e 4,4 falsos negativos por imagem. O F1 de teste ficou 0,0173 abaixo da validação, enquanto AP50 caiu 0,0125, diferenças compatíveis com transferência moderada entre duas amostras de 40 imagens. O viés positivo indica 2,08 detecções excedentes por imagem em média. A Figura 2 mostra dois casos reais do teste: no primeiro, falsos positivos e falsos negativos se compensam na contagem; no segundo, a revocação completa vem acompanhada de supercontagem por falsos positivos.

Esses exemplos mostram por que a contagem não deve ser lida isoladamente. Uma imagem pode ter erro absoluto nulo e ainda conter trocas locais entre omissões e detecções excedentes; outra pode recuperar todos os pontos anotados e, mesmo assim, gerar carga de




Figura 2. Exemplos qualitativos do teste com YOLO11s, pseudo-caixa de 144 pixels e confiança 0,35. No cabeçalho, Anotadas é o total de células de referência e Preditas é o total de detecções. VP indica verdadeiro positivo (caixa verde), FP falso positivo (caixa laranja com X) e FN falso negativo (círculo vermelho), no pareamento por IoU 0,50.

revisão por duplicidades ou estruturas confundidas com células. Por isso, AP, F1, MAE e inspeção qualitativa são complementares neste problema.

Na análise exploratória por tercís, o MAE foi 4,15 em imagens com 5–16 células, 3,69 entre 17–30 e 6,07 entre 32–94. A faixa mais densa concentrou maior erro absoluto, embora o F1 global permaneça 0,8190. A mediana global do erro foi 3 células. Esses estratos foram definidos depois da avaliação principal e não devem ser interpretados como hipóteses confirmatórias, mas ajudam a localizar onde a contagem se torna mais sensível a duplicidades e omissões.

A avaliação por distância ao ponto confirma que o resultado não depende apenas da geometria da pseudo-caixa. Como núcleos vizinhos distam em mediana 72 pixels, raios abaixo desse valor associam cada predição ao núcleo correto, não a um adjacente. No teste, o F1 foi 0,812 em $R = 32$ pixels e 0,821 em $R = 48$, coincidindo com o F1 por IoU 0,50 (0,819). Duas medidas de natureza distinta, portanto, indicam localização efetiva dos núcleos anotados.

4.4. Interpretação

O experimento não recupera fronteiras celulares; ele aprende uma vizinhança quadrada ao redor do núcleo. AP75 alta indica concordância com a regra da Equação 1, não segmentação precisa de núcleo ou citoplasma. Essa distinção também limita comparações diretas com métodos de segmentação ou classificação Bethesda, pois métrica, unidade de análise, partição e semântica do rótulo precisam coincidir para sustentar superioridade numérica [Jiang et al. 2023, Kalbhor et al. 2023].

A objeção de que o IoU contra um alvo sintético seria igualmente artificial é respondida pela avaliação por distância: como o F1 por ponto converge ao F1 por IoU, a métrica não depende criticamente da geometria adotada, e o núcleo anotado – único ground truth espacial da CRIC – é de fato recuperado. Ainda assim, pontos contêm informação de instância que rótulos globais não possuem. A literatura de supervisão

pontual mostra que essa informação pode orientar localização e segmentação com menor custo de anotação [Chen et al. 2021, Xia et al. 2023]. O resultado da RQ1 acrescenta uma observação prática: quando pontos são convertidos em caixas, a geometria escolhida deve ser reportada e testada.

A correlação 0,9434 mostra que o modelo acompanha a variação de carga celular entre imagens; o MAE de 4,68 e o viés de 2,08 revelam erro residual e tendência de supercontagem. As causas prováveis, não separadas por este experimento, são duplicidade em grupos sobrepostos, estruturas não celulares confundidas com o alvo e células visíveis sem ponto correspondente na anotação. Distinguir essas causas exige revisão cega de falsos positivos por especialista.

5. Conclusão

Este estudo tratou a conversão de pontos nucleares em caixas como variável científica. Para a RQ1, observou-se um platô de F1 entre 96 e 192 pixels, com compromissos distintos de AP50, revocação e contagem. Para a RQ2, YOLO11s foi o melhor ponto operacional, embora a vantagem sobre YOLO11n tenha sido pequena e YOLO11m tenha apresentado maior revocação à custa de falsos positivos. Para a RQ3, o modelo selecionado obteve AP50 0,8723, F1 0,8190 e MAE 4,68 no teste retido; a avaliação por distância ao ponto produziu F1 equivalente, reforçando que o detector localiza os núcleos anotados e não apenas se ajusta à convenção da pseudo-caixa.

A conclusão principal não é que 144 pixels ou YOLO11s sejam universais. O resultado relevante é que a definição espacial criada a partir de pontos altera de forma mensurável detecção e contagem e, portanto, precisa fazer parte do protocolo reportado. Em termos práticos, o detector de classe única pode funcionar como etapa anterior a um classificador celular ou a uma revisão assistida, desde que falsos positivos e duplicidades sejam analisados. O trabalho não reivindica caixas anatômicas nem uso diagnóstico; sua contribuição é metodológica, ao trazer para a citologia cervical a pergunta de como a região derivada de pontos influencia localização, calibração e contagem.

A evidência mais importante para uso prático é que localização e contagem se comportam de forma relacionada, mas não equivalente. O caso com erro absoluto zero no teste ainda apresentou falsos positivos e falsos negativos, enquanto o caso de supercontagem recuperou todos os pontos anotados, mas introduziu detecções excedentes. Assim, um protocolo para citologia cervical com pontos deve reportar, no mínimo, tamanho da pseudo-caixa, limiar de confiança, F1 por IoU, F1 por distância ao ponto, erro de contagem e exemplos qualitativos de acertos e falhas. Essa combinação evita que o resultado seja reduzido a uma única métrica ou à escolha de uma caixa.

Como limitações, as métricas de IoU descrevem consistência com um alvo sintético, cada configuração foi treinada uma vez, a avaliação usou uma única base e a separação foi por imagem, não por paciente. Além disso, os intervalos de bootstrap quantificam variação entre imagens, mas não a incerteza de treinamento; diferenças pequenas no platô de F1 não devem ser generalizadas sem repetições. Trabalhos futuros devem repetir o sweep com múltiplas sementes, comparar pseudo-caixas a formulações que aprendem extensão a partir dos pontos [Chen et al. 2023] e anotar uma amostra com contornos manuais para calibrar a avaliação atual.

Os artefatos de reprodução estão no repositório público [Sousa 2026].

Referências

- Chen, P., Cai, X., Chen, Y., Chen, G., Zheng, F., Keutzer, K., Lu, T., and Li, X. (2023). P2BNet: Point-to-box network for object detection with point annotations. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(10):12244–12259.
- Chen, Z., Chen, Z., Liu, J., Zheng, Q., Zhu, Y., Zuo, Y., Wang, Z., Guan, X., Wang, Y., and Li, Y. (2021). Weakly supervised histopathology image segmentation with sparse point annotations. *IEEE Journal of Biomedical and Health Informatics*, 25(5):1673–1685.
- Jiang, P., Li, X., Shen, H., Chen, Y., Wang, L., Chen, H., Feng, J., and Liu, J. (2023). A systematic review of deep learning-based cervical cytology screening: From cell identification to whole slide image analysis. *Artificial Intelligence Review*, 56(Suppl 2):2687–2758.
- Kalbhor, M., Shinde, S., Wajire, P., and Jude, H. (2023). CerviCell-detector: An object detection approach for identifying the cancerous cells in pap smear images of cervical cancer. *Heliyon*, 9(11):e22324.
- Rezende, M. T., Silva, R., Bernardo, F. d. O., Tobias, A. H. G., Oliveira, P. H. C., Machado, T. M., Costa, C. S., Medeiros, F. N. S., Ushizima, D. M., Carneiro, C. M., and Bianchi, A. G. C. (2021). CRIC searchable image database as a public platform for conventional pap smear cytology data. *Scientific Data*, 8(1):151.
- Singh, D., Vignat, J., Lorenzoni, V., Eslahi, M., Ginsburg, O., Lauby-Secretan, B., Arbyn, M., Basu, P., Bray, F., and Vaccarella, S. (2023). Global estimates of incidence and mortality of cervical cancer in 2020: A baseline analysis of the WHO global cervical cancer elimination initiative. *The Lancet Global Health*, 11(2):e197–e206.
- Sousa, J. C. R. (2026). Pesquisa-Jean: Código, configurações e materiais do artigo. <https://github.com/JeanCarlos899/Pesquisa-Jean>. Repositório público do projeto.
- Xia, L., Qu, Z., An, J., and Gao, Z. (2023). A weakly supervised method with colorization for nuclei segmentation using point annotations. *IEEE Transactions on Instrumentation and Measurement*, 72:1–11.